

a4_written_answer

1. Attention Exploration (14 points)

(a): i. 当 *query* 向量 q 与某个 *key* 向量 k_j 的相似度很高, 即 $k_j^T q$ 远大于其他 *key* 的点积时, *softmax* 后的注意力分布 α 会将几乎所有分布压在 α_j 上

ii. 输出向量 c 几乎就是第 j 个 *value* 向量 v_j

(b): $q = k_a + k_b$

(c): i. 在噪声很小, *key* 方向几乎与 μ_i 一样时, 选 $q = k_a + k_b$ 仍然能使注意力集中在 a 和 b 之间, 所以 $c \approx \frac{1}{2}(v_a + v_b)$

ii. 在这种协方差设定下, 虽然 *key* 的方向大致没变, 但 k_a 的长度波动很大, 所以用同一个 q 得到的打分 e_a 有很大随机性。 *softmax* 会把这种长度差放大成注意力权重的差异: 有时几乎全看 v_a , 有时更平均, 有时更偏向别的 *value*。结果就是, 输出向量 c 在不同样本之间非常不稳定, 方差明显高于 (i) 的情况, 再也不能稳定地近似 $c \approx \frac{1}{2}(v_a + v_b)$

(d): (i) 选择: $q_1 = \mu_a + \mu_b, q_2 = \mu_a - \mu_b$ 这两个 *query* 会关注到相同的两个 *key*, 得到的输出平均后接近: $c \approx \frac{1}{2}(v_a + v_b)$

(ii) 由于 k_a 的范数波动很大: c_1 和 c_2 的输出各自方差都很高 (不稳定), 但因为 q_1 与 q_2 对 v_b 的偏好方向相反, 它们的误差在平均时会部分抵消。所以: 最终输出 $c \approx \frac{1}{2}(v_a + v_b)$ 的方差会明显小于单头注意力, 结果更稳定。

2. Position Embeddings

(a): i. 由于对输入乘以置换矩阵 P 会使 Q, K, V 都变成各自左乘 P , 因此 $Z_{perm} = \text{softmax}(Q_{perm} K_{perm}^T) V_{perm} = P \text{softmax}(Q K^T) V = P Z$

ii. 这一性质意味着 Transformer (无位置编码时) 对词序完全不敏感: 如果打乱输入 token 顺序, 它只会在输出中以同样方式打乱, 而不会改变内容。这对 NLP 是非常糟糕的, 因为语言语义高度依赖词序 (如主谓宾关系、因果顺序等)。因此 Transformer 必须加入位置编码才能理解自然语言。

(b): i. 是的, 位置编码会帮助解决前面的问题。因为位置编码为每个 token 引入唯一的位置信息, 使 Transformer 不再对输入的置换保持等变性, 从而能够利用词序信息来理解语言。

ii. 不会。不同位置 t 具有不同的正弦和余弦值, 因此它们的向量 $\Phi(t)$ 不可能完全一致。位置编码专门设计为在实际序列长度范围内保持唯一性

4. Considerations in pretrained knowledge

(a). 非预训练模型只看到有限的 $\text{name} \leftrightarrow \text{birthplace}$ 监督样本, 不足以覆盖世界上大多数人名, 基本是在瞎猜常见城市, 所以准确率接近或略高于 baseline。

预训练模型在大规模语料 (维基) 中已经多次见到这些人名及其出生地附近的上下文, 微调时只是把已有知识对齐到“问答格式”, 因此能显著高于 10%。